

# Rachunek prawdopodobieństwa i statystyka

## Wnioskowanie statystyczne

Maciej Smółka

Wydział Informatyki AGH

Semestr zimowy 2024/25

# Rodzaje zbieżności zmiennych losowych I

Niech  $X_1, X_2, \dots$  i  $X$  będą zmiennymi losowymi o wartościach w tej samej przestrzeni  $\mathcal{X}$ .

## Definicja

Ciąg  $X_n$  jest **zbieżny do  $X$  według prawdopodobieństwa** (lub **stochastycznie**) jeśli dla każdego  $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P(|X_n - X| < \varepsilon) = 1.$$

## Definicja

Ciąg  $X_n$  jest **zbieżny do  $X$  z prawdopodobieństwem 1** jeśli

$$P(\lim_{n \rightarrow \infty} X_n = X) = 1.$$

# Rodzaje zbieżności zmiennych losowych II

## Definicja

Założmy, że  $\mathcal{X} = \mathbb{R}^k$  i niech  $F_{X_n}$  będzie dystrybuantą  $X_n$ , a  $F_X$  dystrybuantą  $X$ . Ciąg  $X_n$  jest **zbieżny do  $X$  według dystrybuant** jeśli dla każdego  $x \in \mathbb{R}^k$  takiego, że  $F_X$  jest ciągła w  $x$  zachodzi warunek

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x).$$

# Zależności między rodzajami zbieżności

- 1 Jeśli  $X_n \rightarrow X$  z prawdopodobieństwem 1, to  $X_n \rightarrow X$  według prawdopodobieństwa.
- 2 Jeśli  $X_n \rightarrow X$  według prawdopodobieństwa, to istnieje podciąg  $X_{n_k}$  taki, że  $X_{n_k} \rightarrow X$  z prawdopodobieństwem 1.
- 3 Jeśli  $X_n \rightarrow X$  według prawdopodobieństwa, to  $X_n \rightarrow X$  według dystrybuant.
- 4 Niech  $c \in \mathbb{R}$  będzie stałą.  $X_n \rightarrow c$  według prawdopodobieństwa wtedy i tylko wtedy, gdy  $X_n \rightarrow c$  według dystrybuant.

# Podstawowe zagadnienia wnioskowania statystycznego

Niech zmienna losowa  $X$  określa model rozkładu pewnej cechy (cech) w ustalonym zbiorze instancji (tzw. **populacji generalnej**). Innymi słowy, przyjmujemy, że wartości cech zachowują się jakby zostały wybrane *losowo* zgodnie z rozkładem zmiennej  $X$ . Do podstawowych zagadnień wnioskowania statystycznego należą:

- oszacowanie wielkości charakteryzujących rozkład  $X$  (np. wartości średniej albo wariancji);
- weryfikacja hipotez dotyczących rozkładu  $X$  (np. zgodności tego rozkładu z rozkładem normalnym).

# Model statystyczny

## Definicja

**Modelem statystycznym** nazywamy parę  $(\mathcal{X}, \mathcal{P})$ , gdzie  $\mathcal{P}$  jest rodziną rozkładów prawdopodobieństwa (miar probabilistycznych) na zbiorze  $\mathcal{X}$ . Zazwyczaj przyjmuje się, że

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$

dla pewnego zbioru **parametrów modelu**  $\Theta$ . Mówimy, że model jest **identyfikowalny** jeśli  $P_{\theta_1} \neq P_{\theta_2}$  dla  $\theta_1 \neq \theta_2$ .

# Przykład

Założmy, że badamy zależność między wzrostem a wiekiem dzieci w wieku szkolnym, przy czym dysponujemy równomiernie wybraną próbką takich dzieci. Model rozkładu tych cech w badanej populacji stanowi zmienna losowa  $(Wzrost, Wiek)$ , przy czym wzrost jest liniowo zależny od wieku z uwzględnieniem błędu losowego o rozkładzie normalnym ze średnią 0, tzn.

$$Wzrost = b_0 + b_1 \cdot Wiek + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma)$$

dla pewnych  $b_0, b_1, \sigma$ . W tej sytuacji

$$\theta = (b_0, b_1, \sigma) \in \Theta \subset \mathbb{R}^3.$$

# Prawdziwość modelu a jego użyteczność

## Uwaga

Nie zakładamy, że rozkład zmiennej  $X$  należy do rodziny  $\mathcal{P}$ . W praktyce taka sytuacja zdarza się rzadko. Wobec tego trudno mówić o *prawdziwości* modelu statystycznego. Natomiast model powinien stanowić *użyteczne* uproszczenie lub aproksymację rzeczywistości.



# Klasy modeli statystycznych

Model statystyczny nazywamy:

- **parametrycznym** jeśli  $\Theta \subset \mathbb{R}^k$ ;
- **nieparametrycznym** jeśli  $\Theta \subset V$  dla pewnej nieskończenie wymiarowej przestrzeni wektorowej  $V$ ;
- **semi-parametrycznym** jeśli  $\Theta \subset \mathbb{R}^k \times V$ .

# Prosta próba losowa

## Definicja

**Prostą próbą losową o licznosci  $n$**  nazywamy ciąg niezależnych zmiennych losowych  $X_1, \dots, X_n$  o wartościach w  $\mathcal{X}$  i o tym samym rozkładzie  $P_\theta \in \mathcal{P}$ .

## Definicja

Ciąg wartości  $x_1, \dots, x_n \in \mathcal{X}$  takich, że

$$X_1(\omega) = x_1, \dots, X_n(\omega) = x_n$$

dla pewnego  $\omega$  nazywamy **realizacją prostej próby losowej  $X_1, \dots, X_n$** .

# Dystrybuanta empiryczna

W dalszym ciągu będziemy zakładać, że  $\mathcal{X} = \mathbb{R}$ .

## Definicja

**Dystrybuantą empiryczną** nazywa się funkcję określoną wzorem

$$\hat{F}_n(x) = \frac{1}{n} \# \{i \in \{1, \dots, n\} : x_i \leq x\}$$

gdzie  $x_1, \dots, x_n$  jest realizacją prostej próby losowej.

## Uwaga

Dla każdego  $x \in \mathbb{R}$   $F_n(x)$  jest zmienną losową, tj.

$$\hat{F}_n(x, \omega) = \frac{1}{n} \# \{i \in \{1, \dots, n\} : X_i(\omega) \leq x\}.$$

# Asymptotyczne zachowanie dystrybuanty empirycznej

Następujące twierdzenie zostało sformułowane przez W. I. Gliwenkę<sup>1</sup> i F. P. Cantelli'ego<sup>2</sup>.

## Twierdzenie Gliwenki-Cantelli'ego

Jeśli  $F$  jest dystrybuantą rozkładu  $P_\theta$ , to

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \rightarrow 0 \quad (n \rightarrow \infty)$$

z prawdopodobieństwem 1.

---

<sup>1</sup>**Walery Iwanowicz Gliwenko** (1897–1940) — ukraiński matematyk

<sup>2</sup>**Francesco Paolo Cantelli** (1875–1966) — włoski matematyk

# Statystyki

## Definicja

**Statystyką** nazywa się zmienną losową będącą funkcją prostej próby losowej  $T(X_1, \dots, X_n)$ .

**Średnią w prostej próbie losowej** nazywa się statystykę

$$\bar{X} = \bar{X}_n = \frac{X_1 + \dots + X_n}{n}.$$

**Wariancją w prostej próbie losowej** nazywa się statystykę

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

# Prawo wielkich liczb

Jeśli  $P_\theta$  ma skończoną wartość średnią  $\mu$  i wariancję, to

$$\overline{X}_n \rightarrow \mu$$

z prawdopodobieństwem 1 przy  $n \rightarrow \infty$ .

# Wielkości opisujące rozkład średniej

Niech rozkład  $P_\theta$  ma wartość średnią  $\mu$  i wariancję  $\sigma^2$ . Ponieważ  $X_1, \dots, X_n$  są niezależne i mają rozkład  $P_\theta$ , więc

$$\begin{aligned}E(\bar{X}) &= \frac{1}{n}EX_1 + \dots + \frac{1}{n}EX_n = \mu \\Var(\bar{X}) &= \frac{1}{n^2}VarX_1 + \dots + \frac{1}{n^2}VarX_n = \frac{\sigma^2}{n} \\ \sigma_{\bar{X}} &= \frac{\sigma}{\sqrt{n}}\end{aligned}$$

# Centralne Twierdzenie Graniczne

Oznaczmy

$$Z_n = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}.$$

Następujące twierdzenie nosi również nazwę twierdzenia Lindeberga<sup>3</sup>-Lévy'ego<sup>4</sup>.

## Twierdzenie Lindeberga-Lévy'ego

Niech  $X_n$  będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie ze skończoną średnią  $\mu$  i wariancją  $\sigma^2 > 0$ . Wtedy ciąg  $Z_n$  jest zbieżny według dystrybuant do zmiennej losowej  $Z$  o standardowym rozkładzie normalnym  $\mathcal{N}(0, 1)$ .

---

<sup>3</sup>**Jarl Waldemar Lindeberg** (1876–1932) — fiński matematyk

<sup>4</sup>**Paul Pierre Lévy** (1886–1971) — francuski matematyk



## Wniosek dla prostej próby losowej

Jeśli  $\Phi = \Phi_{0,1}$  jest dystrybuantą standardowego rozkładu normalnego, to dla dowolnych  $a, b \in \mathbb{R}$  takich, że  $a \leq b$  zachodzi

$$P\left(a \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq b\right) \rightarrow P(a \leq Z \leq b) = \Phi(b) - \Phi(a) \quad (n \rightarrow \infty).$$

Inaczej mówiąc, prawdopodobieństwo  $P(a \leq \bar{X} \leq b)$  jest dla dużych liczności prób w przybliżeniu równe

$$P\left(\frac{a - \mu}{\frac{\sigma}{\sqrt{n}}} \leq Z \leq \frac{b - \mu}{\frac{\sigma}{\sqrt{n}}}\right) = P\left(a \leq \frac{\sigma}{\sqrt{n}}Z + \mu \leq b\right),$$

czyli rozkład średniej dla dużych  $n$  jest w przybliżeniu równy rozkładowi normalnemu  $\mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$ .

# Uwaga

Przybliżenie normalne dla rozkładu średniej zasadniczo uważa się za wystarczająco dokładne dla  $n \geq 25$ .

# Estymatory punktowe

## Definicja

**Estymatorem** (lub **estymatorem punktowym**) parametru  $\theta$  nazywa się statystykę  $\hat{\theta}(X_1, \dots, X_n)$  służącą do oszacowania wartości  $\theta$ . Liczbę  $\hat{\theta}(x_1, \dots, x_n)$  dla konkretnej realizacji próby losowej nazywa się **wartością estymatora** albo **estymatą**.

# Obciążenie estymatora

Liczbę

$$Bias(\hat{\theta}) = E\hat{\theta} - \theta = E\hat{\theta}(X_1, \dots, X_n) - \theta$$

nazywamy **obciążeniem estymatora** [ang. *bias*]. Jeśli  $Bias(\hat{\theta}) = 0$ , to estymator nazywamy **nieobciążonym** [ang. *unbiased*], w przeciwnym razie estymator nazywamy **obciążonym** [ang. *biased*]. Estymator nazywamy **asymptotycznie nieobciążonym** jeśli

$$\lim_{n \rightarrow \infty} Bias(\hat{\theta}) = 0.$$

# Estymator wartości średniej

Wiemy, że

$$E\bar{X} = \mu,$$

zatem  $\bar{X}$  jest nieobciążonym estymatorem wartości średniej  $\mu$ .

# Estymatory wariancji I

Estymatorem  $\sigma^2$  jest wariancja w próbie, tzn.

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left( \sum_{i=1}^n X_i^2 - \frac{1}{n} \left( \sum_{i=1}^n X_i \right)^2 \right).$$

Ponieważ  $\sigma_X^2 = \mu_{X^2} - \mu_X^2$ , więc  $\mu_{X^2} = \sigma_X^2 + \mu_X^2$ , a zatem oznaczając  $Y = \sum_{i=1}^n X_i$  otrzymujemy

$$\begin{aligned} E(S^2) &= \frac{1}{n-1} \left( \sum_{i=1}^n EX_i^2 - \frac{1}{n} EY^2 \right) \\ &= \frac{1}{n-1} \left( \sum_{i=1}^n (\sigma^2 + \mu^2) - \frac{1}{n} (\sigma_Y^2 + \mu_Y^2) \right) \\ &= \frac{1}{n-1} \left( n\sigma^2 + n\mu^2 - \frac{1}{n} n\sigma^2 - \frac{1}{n} n^2 \mu^2 \right) = \sigma^2, \end{aligned}$$

# Estymatory wariancji II

co oznacza, że  $S^2$  jest nieobciążonym estymatorem  $\sigma^2$ . Konsekwentnie,

$$M_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$$

jest obciążonym estymatorem wariancji, ponieważ

$$\text{Bias}(M_2) = E(M_2) - \sigma^2 = \frac{n-1}{n} E(S^2) - \sigma^2 = -\frac{1}{n} \sigma^2.$$

Jest to natomiast oczywiście estymator asymptotycznie nieobciążony.

# Estymatory nieobciążone o minimalnej wariancji

## Definicja

**Estymatorem nieobciążonym o minimalnej wariancji** [ang. *minimum-variance unbiased estimator (MVUE)*] nazywamy taki estymator nieobciążony  $\hat{\theta}$ , że dla dowolnej wartości parametru  $\theta \in \Theta$  i dowolnego estymatora nieobciążonego  $\tilde{\theta}$  zachodzi nierówność

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta}).$$



# Przykłady

- ❶  $\bar{X}$  jest MVUE w modelu

$$\mathcal{P} = \{\mathcal{N}(\mu, \sigma_0) : \mu \in \mathbb{R}\}.$$

dla ustalonego  $\sigma_0 > 0$ .

- ❷  $\bar{X}$  i  $S^2$  są MVUE dla  $\mu$  i  $\sigma^2$  w modelu

$$\mathcal{P} = \{\mathcal{N}(\mu, \sigma) : \mu \in \mathbb{R}, \sigma > 0\}.$$

# Błąd średniokwadratowy

## Definicja

**Błędem średniokwadratowym** [ang. *mean squared error (MSE)*] estymatora  $\hat{\theta}$  parametru  $\theta$  nazywamy liczbę

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

# Estymatory dominujące i dopuszczalne

## Definicja

Mówimy, że **estymator**  $\theta_1$  **dominuje nad**  $\theta_2$  jeśli dla każdej wartości  $\theta \in \Theta$

$$MSE(\theta_1) \leq MSE(\theta_2)$$

i istnieje taka wartość  $\theta$ , dla której nierówność jest ostra.

Estymator nazywamy **dopuszczalnym** jeśli nie istnieje estymator nad nim dominujący.

# Związek między obciążeniem a MSE

## Stwierdzenie

Dla dowolnego estymatora  $\hat{\theta}$  zachodzi równość

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + Bias(\hat{\theta})^2.$$

# Dowód stwierdzenia

Oznaczmy  $\mu_{\hat{\theta}} = E(\hat{\theta})$ . Wówczas mamy

$$(\hat{\theta} - \theta)^2 = (\hat{\theta} - \mu_{\hat{\theta}} + \mu_{\hat{\theta}} - \theta)^2 = (\hat{\theta} - \mu_{\hat{\theta}})^2 + 2(\hat{\theta} - \mu_{\hat{\theta}})(\mu_{\hat{\theta}} - \theta) + (\mu_{\hat{\theta}} - \theta)^2.$$

Licząc wartość średnią obu stron otrzymujemy

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + 2(\mu_{\hat{\theta}} - \theta)E(\hat{\theta} - m_{\hat{\theta}}) + Bias(\hat{\theta})^2 = Var(\hat{\theta}) + Bias(\hat{\theta})^2.$$

# Wnioski

- 1 MVUE ma najmniejszy MSE spośród estymatorów nieobciążonych danego parametru.
- 2 W danym modelu może istnieć estymator obciążony o mniejszym MSE od dowolnego estymatora nieobciążonego.

## Przykład

W rodzinie rozkładów normalnych  $S^2$  jest nieobciążonym estymatorem wariancji i

$$MSE(S^2) = Var(S^2) = \frac{2\sigma^4}{n-1}$$

Natomiast dla innego estymatora wariancji  $T^2 = \frac{n-1}{n+1}S^2$  mamy

$$MSE(T^2) = \frac{2\sigma^4}{n+1} < MSE(S^2),$$

pomimo że estymator jest obciążony.

# Błąd standardowy

## Definicja

**Błędem standardowym**  $SE(\hat{\theta})$  estymatora  $\hat{\theta}$  nazywamy albo jego odchylenie standardowe, albo dowolny estymator tego odchylenia standardowego.



# Przykład

$$SE(\bar{X}) = \frac{S}{\sqrt{n}}, \text{ gdzie } S = \sqrt{S^2}.$$

# Funkcja wiarygodności

## Definicja

**Funkcją wiarygodności** [ang. *likelihood function*] dla modelu  $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$  nazywamy funkcję

$$\mathcal{L} : \Theta \times \mathbb{R}^n \ni (\theta, x) \mapsto \mathcal{L}(\theta|x) \in [0, +\infty)$$

wyznaczającą rozkład łączny obserwowanych danych jako funkcję parametru  $\theta$ .

# Funkcja wiarygodności dla prostej próby losowej

Niech  $X_1, \dots, X_n$  będzie prostą próbą losową. Jeśli  $P_\theta$  są rozkładami ciągłymi o gęstościach  $f_\theta$ , to

$$\mathcal{L}(\theta|x) = f_\theta(x_1) \cdots f_\theta(x_n).$$

Jeśli  $P_\theta$  są rozkładami dyskretnymi z funkcjami prawdopodobieństwa  $p_\theta$ , to

$$\mathcal{L}(\theta|x) = p_\theta(x_1) \cdots p_\theta(x_n).$$

# Logarytmiczna funkcja wiarygodności

Ze względów obliczeniowych często rozważa się *logarytmiczną funkcję wiarygodności* [ang. *log-likelihood function*], tzn.

$$l(\theta|x) = \ln \mathcal{L}(\theta|x).$$

Dla rozkładów ciągłych mamy

$$l(\theta|x) = \ln f_{\theta}(x_1) + \cdots + \ln f_{\theta}(x_n),$$

a dla rozkładów dyskretnych

$$l(\theta|x) = \ln p_{\theta}(x_1) + \cdots + \ln p_{\theta}(x_n),$$

# Przykład

Niech

$$\mathcal{P} = \{\mathcal{N}(\theta_1, \sqrt{\theta_2}) : \theta_1 \in \mathbb{R}, \theta_2 > 0\}.$$

Wtedy mamy

$$\mathcal{L}(\theta_1, \theta_2 | x) = \frac{1}{\sqrt{(2\pi\theta_2)^n}} e^{-\frac{1}{2\theta_2} \sum_{i=1}^n (x_i - \theta_1)^2}$$

oraz

$$l(\theta_1, \theta_2 | x) = -\frac{n}{2} \ln(2\pi\theta_2) - \frac{1}{2\theta_2} \sum_{i=1}^n (x_i - \theta_1)^2.$$

# Przykład

Dla

$$\mathcal{P} = \{Pois(\theta) : \theta > 0\}$$

mamy

$$\mathcal{L}(\theta|x) = e^{-n\theta} \frac{\theta^{x_1 + \dots + x_n}}{x_1! \dots x_n!}$$

oraz

$$l(\theta|x) = -n\theta + \left( \sum_{i=1}^n x_i \right) \ln \theta - \sum_{i=1}^n \ln(x_i!).$$

# Metoda największej wiarygodności

Jest to metoda konstrukcji estymatorów opracowana przez R. Fishera<sup>5</sup>.

**Estymatorem największej wiarygodności** [ang. *maximum likelihood estimator (MLE)*] nazywamy funkcję  $\hat{\theta}$ , która przy ustalonych wartościach obserwacji  $x = (x_1, \dots, x_n)$  maksymalizuje wartość funkcji wiarygodności lub, alternatywnie, wartość logarytmicznej funkcji wiarygodności, tzn.

$$\mathcal{L}(\hat{\theta}(x)|x) = \max_{\theta \in \Theta} \mathcal{L}(\theta|x) \quad \text{albo} \quad l(\hat{\theta}(x)|x) = \max_{\theta \in \Theta} l(\theta|x).$$

---

<sup>5</sup>Ronald Aylmer Fisher (1890–1962) — brytyjski statystyk i genetyk

# Obliczanie MLE

Jeśli funkcja wiarygodności jest różniczkowalna względem  $\theta = (\theta_1, \dots, \theta_k) \in \mathbb{R}^k$  dla dowolnego  $x$ , to MLE można czasem wyznaczyć analitycznie korzystając z warunku koniecznego optymalności, tzn. rozwiązując układ równań

$$\frac{\partial}{\partial \theta_1} \mathcal{L}(\theta|x) = \dots = \frac{\partial}{\partial \theta_k} \mathcal{L}(\theta|x) = 0$$

albo

$$\frac{\partial}{\partial \theta_1} l(\theta|x) = \dots = \frac{\partial}{\partial \theta_k} l(\theta|x) = 0$$

Jeśli MLE nie da się wyliczyć analitycznie, wyznacza się je przy użyciu algorytmów optymalizacji.



## Przykład

Dla  $\mathcal{P} = \{Pois(\theta) : \theta > 0\}$  mamy

$$\frac{\partial}{\partial \theta} l(\theta|x) = -n + \left( \sum_{i=1}^n x_i \right) \frac{1}{\theta}.$$

Zatem MLE spełnia równanie

$$-n + \left( \sum_{i=1}^n x_i \right) \frac{1}{\hat{\theta}} = 0,$$

skąd otrzymujemy

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

# Własności MLE

- 1 MLE są asymptotycznie nieobciążone.
- 2 Jeśli  $\hat{\theta}$  jest MLE parametru  $\theta$  i  $h$  jest odwzorowaniem wzajemnie jednoznacznym, to  $h(\hat{\theta})$  jest MLE parametru  $h(\theta)$ .

# Metoda momentów

Założmy, że dla każdego  $\theta = (\theta_1, \dots, \theta_k)$  rozkłady  $P_\theta$  mają skończone momenty do rzędu  $k$  oraz że istnieją funkcje  $h_p$  takie, że

$$EX_i^p = h_p(\theta_1, \dots, \theta_k)$$

dla  $p = 1, \dots, k$ . **Estymatory metody momentów** opracowanej przez K. Pearsona<sup>6</sup> otrzymujemy rozwiązując równania

$$\frac{1}{n} \sum_{i=1}^n X_i^p = h_p(\hat{\theta}_1, \dots, \hat{\theta}_k).$$

---

<sup>6</sup>Karl (Carl) Pearson (1857–1936) — angielski matematyk i biostatystyk

# Uwagi

- 1 Momenty zwykłe można zastąpić momentami centralnymi. Wtedy równania metody momentów mają postać

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^p = \tilde{h}_p(\hat{\theta}_1, \dots, \hat{\theta}_k).$$

- 2 Drugi moment centralny  $M_2$  można zastąpić wariancją w próbie  $S^2$ .
- 3 Estymatory metody momentów na ogół nie mają zbyt dobrych własności, ale są stosunkowo łatwe do wyznaczenia. Mogą być stosowane np. jako punkty startowe dla algorytmów optymalizacji w metodzie największej wiarygodności.

# Przykład

Niech

$$\mathcal{P} = \{ \textit{Gamma}(\theta_1, \theta_2) : \theta_1 > 0, \theta_2 > 0 \}.$$

Wtedy

$$E(X_i) = \frac{\theta_1}{\theta_2} \quad \text{Var}(X_i) = \frac{\theta_1}{\theta_2^2}.$$

Biorąc  $S^2$  zamiast  $M_2$  otrzymujemy równania metody momentów

$$\bar{X} = \frac{\hat{\theta}_1}{\hat{\theta}_2} \quad S^2 = \frac{\hat{\theta}_1}{\hat{\theta}_2^2}.$$

A stąd

$$\hat{\theta}_1 = \frac{(\bar{X})^2}{S^2} \quad \hat{\theta}_2 = \frac{\bar{X}}{S^2}.$$

# Przedział ufności dla rozkładu ciągłego

Pojęcie przedziału ufności zostało wprowadzone przez J. Neymana<sup>7</sup>.

## Definicja

Założmy, że rozkłady  $P_\theta$  są ciągłe. Niech  $\underline{U}, \overline{U}$  będą statystykami takimi, że  $P(\underline{U} \leq \overline{U}) = 1$  i  $0 < \alpha < 1$ . **Przedziałem ufności** [ang. *confidence interval*] dla parametru  $\theta$  na poziomie ufności [ang. *confidence level*]  $1 - \alpha$  nazywamy przedział losowy  $[\underline{U}, \overline{U}]$  o ile spełniona jest równość

$$P(\underline{U} \leq \theta \leq \overline{U}) = 1 - \alpha$$

<sup>7</sup>Jerzy Sława-Neyman (1894–1981) — polski matematyk i statystyk

# Przedział ufności dla rozkładu dykretnego

Jeśli rozkłady  $P_\theta$  są dyskretne, to modyfikuje się definicję przedziału ufności zmieniając równość w ostatnim warunku na nierówność, tzn. wymagamy tylko aby

$$P\left(\underline{U} \leq \theta \leq \overline{U}\right) \geq 1 - \alpha$$

# Uwagi

- 1 Przedział ufności nie jest stałym przedziałem, tylko zmienną losową.
- 2 Standardowo stosowany poziom ufności to 95% (inaczej 0,95, czyli  $\alpha = 0,05$ ), inne często stosowane to 99% i 90%.



# Konstrukcja przedziału ufności

Wybieramy estymator punktowy  $U$  parametru  $\theta$ , którego rozkład dokładny lub asymptotyczny jest znany. Następnie bierzemy liczby  $a$  i  $b$  takie, że

$$P(a \leq U \leq b) = 1 - \alpha.$$

Jeśli nierówność  $a \leq U \leq b$  da się przekształcić do równoważnej nierówności

$$\underline{f}(U) \leq \theta \leq \bar{f}(U),$$

to  $[\underline{f}(U), \bar{f}(U)]$  jest oczekiwanym przedziałem ufności na poziomie ufności  $1 - \alpha$ .

# Uwaga

Zaprezentowana konstrukcja nie daje jednoznacznego określenia przedziału ufności, bo liczby  $a$  i  $b$  można dobrać na wiele sposobów. Zwykle, jeśli nie ma innych istotnych przesłanek, dobiera się je tak, aby

$$P(U < a) = P(U > b) = \frac{1}{2}\alpha$$

W przypadku rozkładów dyskretnych ten warunek zamienia się na

$$P(U < a) \leq \frac{1}{2}\alpha, \quad P(U > b) \leq \frac{1}{2}\alpha.$$

## Średnia w rozkładzie normalnym o znanym $\sigma$ I

Niech  $\mathcal{P} = \{\mathcal{N}(\mu, \sigma) : \mu \in \mathbb{R}\}$  dla pewnego  $\sigma > 0$ . Szukamy przedziału ufności dla  $\mu$ . MVUE (i MLE) w tym przypadku jest  $\bar{X}$ . Wiemy, że  $\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma}{\sqrt{n}})$ , a zatem

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1).$$

Jeśli oznaczymy przez  $z_p$  kwantyl rzędu  $p$  rozkładu  $\mathcal{N}(0, 1)$ , to otrzymamy

$$P(Z < z_{\frac{\alpha}{2}}) = \frac{\alpha}{2} \quad P(Z > z_{1-\frac{\alpha}{2}}) = 1 - P(Z \leq z_{1-\frac{\alpha}{2}}) = \frac{\alpha}{2}.$$

Stąd

$$P(z_{\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}}) = 1 - \alpha.$$

## Średnia w rozkładzie normalnym o znanym $\sigma$ II

Z symetrii rozkładu  $z_{\frac{\alpha}{2}} = -z_{1-\frac{\alpha}{2}}$ , czyli

$$P(-z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}}) = 1 - \alpha.$$

Zatem

$$P(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}) = 1 - \alpha.$$

Oznacza to, że przedziałem ufności na poziomie  $1 - \alpha$  dla  $\mu$  jest

$$\left[ \bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]$$

# Uwagi

- 1 Rezultatem podanej konstrukcji jest tzw. **dwustronny** przedział ufności. Zamiast tego czasem konstruuje się przedziały **jednostronne**, np.

$$\left(-\infty, \bar{X} + z_{1-\alpha} \frac{\sigma}{\sqrt{n}}\right] \quad \text{lub} \quad \left[\bar{X} - z_{1-\alpha} \frac{\sigma}{\sqrt{n}}, +\infty\right).$$

- 2 Spośród przedziałów dwustronnych o tym samym poziomie ufności przedział symetryczny z poprzedniego slajdu jest najkrótszy.

## Średnia w rozkładzie normalnym o nieznanym $\sigma$

Tym razem  $\mathcal{P} = \{\mathcal{N}(\mu, \sigma) : \mu \in \mathbb{R}, \sigma > 0\}$ . Do konstrukcji przedziału ufności zamiast zmiennej  $Z$  bierzemy

$$T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}.$$

Można pokazać, że

$$T \sim t_{n-1},$$

gdzie  $t_n$  jest tzw. **rozkładem**  $t$  o  $n$  stopniach swobody.

# Rozkład $t$

Rozkład  $t$  o  $\nu$  stopniach swobody dla  $\nu > 0$ , zwany także **rozkładem Studenta**<sup>8</sup>, to rozkład ciągły o gęstości

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{\pi\nu}} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}.$$

---

<sup>8</sup>**William Sealy Gosset** (1876–1937) – brytyjski statystyk, ze względu na ograniczenia stawiane przez pracodawcę publikacje naukowe podpisywał pseudonimem **Student**

## Alternatywne określenie rozkładu $t$

Jeśli zmienne losowe  $Z$  i  $V$  są niezależne, a ponadto

$$Z \sim \mathcal{N}(0, 1)$$

i

$$V \sim \chi^2(\nu),$$

to

$$\frac{Z}{\sqrt{\frac{V}{\nu}}} = Z \sqrt{\frac{\nu}{V}} \sim t_{\nu}.$$




# Wielkości opisujące rozkład $t$

- ❶ Średnia dla  $\nu \leq 1$  nie istnieje, dla  $\nu > 1$  jest równa 0.
- ❷ Wariancja jest równa  $\frac{\nu}{\nu-2}$  dla  $\nu > 2$ ,  $+\infty$  dla  $1 < \nu \leq 2$ , nie istnieje dla  $\nu \leq 1$ .
- ❸ Współczynnik asymetrii jest równy 0 dla  $\nu > 3$ , nie istnieje dla  $\nu \leq 3$ .
- ❹ Współczynnik wyostżenia przyjmuje następujące wartości

$$\gamma_2 = \begin{cases} \frac{6}{\nu-4} & \text{dla } \nu > 4, \\ +\infty & \text{dla } 2 < \nu \leq 4, \\ \text{nie istnieje} & \text{dla } \nu \leq 2. \end{cases}$$

# Gęstość rozkładu $t$



## Średnia w rozkładzie normalnym o nieznanym $\sigma$ (c.d.)

Skoro wiemy, że  $T \sim t_{n-1}$ , więc analogicznie jak dla przypadku ze znanym  $\sigma$  korzystając z symetrii rozkładu  $t$  otrzymujemy symetryczny przedział ufności na poziomie  $1 - \alpha$  o następującej postaci

$$\left[ \bar{X} - t_{1-\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} \right],$$

gdzie  $t_{p,\nu}$  jest kwantylem rzędu  $p$  rozkładu  $t_\nu$ .

# Uwaga

Dla  $n \rightarrow \infty$  rozkład  $t$  coraz bardziej przypomina standardowy rozkład normalny. Dla  $n = 30$  te rozkłady są praktycznie nieodróżnialne.

## Porównanie średnich w rozkładach normalnych — znane wariancje

Jeśli mamy dwie **niezależne próby losowe**  $X_1, \dots, X_{n_1}$  i  $Y_1, \dots, Y_{n_2}$  o nieznanych średnich  $m_1$  i  $m_2$ , i znanych odchyleniach standardowych  $\sigma_1$  i  $\sigma_2$ , to

$$Z = \frac{(\bar{X} - \bar{Y}) - (m_1 - m_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1).$$

Stąd przedział ufności na poziomie  $1 - \alpha$  jest równy

$$\left[ \bar{X} - \bar{Y} - z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X} - \bar{Y} + z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right].$$

# Porównanie średnich w rozkładach normalnych — nieznane wariancje I

Zakładamy, że  $\sigma_1 = \sigma_2 = \sigma$ . Wtedy

$$\text{Var}(X - Y) = \frac{\sigma^2}{n_1 + n_2}$$

i można wykazać, że

$$S_p^2 = \frac{(n_1 - 1)S_X^2 + (n_2 - 1)S_Y^2}{n_1 + n_2 - 2}$$

jest nieobciążonym estymatorem  $\sigma^2$ , przy czym

$$T = \frac{(\bar{X} - \bar{Y}) - (m_1 - m_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1 + n_2 - 2}$$

# Porównanie średnich w rozkładach normalnych — nieznanne wariancje II

Stąd przedział ufności na poziomie  $1 - \alpha$  jest równy

$$\left[ \bar{X} - \bar{Y} - t_{1-\frac{\alpha}{2}, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \right. \\ \left. \bar{X} - \bar{Y} + t_{1-\frac{\alpha}{2}, n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right].$$

# Porównanie średnich w rozkładach normalnych — pary obserwacji

Zakładamy, że pary  $(X_1, Y_1), \dots, (X_n, Y_n)$  mają takie same dwuwymiarowe rozkłady normalne i są wzajemnie niezależne, ale  $X_i$  i  $Y_i$  mogą być zależne. W takiej sytuacji zmienne

$$D_i = X_i - Y_i$$

są niezależne i mają rozkład normalny, zatem można jak w jednym z poprzednich przykładów wyznaczyć przedział ufności dla średniej  $m_D$  przy pomocy kwantyli standardowego rozkładu normalnego.



# Wariancja w rozkładzie normalnym I

Jeśli  $X_i \sim \mathcal{N}(0, 1)$  dla każdego  $i$ , to

$$\sum_{i=1}^n X_i^2 \sim \chi^2(n).$$

Podobnie jeśli  $X_i \sim \mathcal{N}(\mu, \sigma)$ , to

$$\sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n).$$

Ponadto można pokazać, że

$$\chi^2 = \sum_{i=1}^n \left( \frac{X_i - \bar{X}}{\sigma} \right)^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

## Wariancja w rozkładzie normalnym II

Stąd

$$P(\chi_{\frac{\alpha}{2}, n-1}^2 \leq \mathcal{X}^2 \leq \chi_{1-\frac{\alpha}{2}, n-1}^2) = 1 - \alpha,$$

gdzie  $\chi_{p,n}^2$  jest kwantylem rzędu  $p$  rozkładu  $\chi^2(n)$ . Korzystając z definicji zmiennej  $\mathcal{X}^2$  otrzymujemy

$$P\left(\frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}, n-1}^2}\right) = 1 - \alpha.$$

Stąd otrzymujemy przedział ufności dla wariancji

$$\left[ S^2 \frac{n-1}{\chi_{1-\frac{\alpha}{2}, n-1}^2}, S^2 \frac{n-1}{\chi_{\frac{\alpha}{2}, n-1}^2} \right]$$

## Wariancja w rozkładzie normalnym III

i dla odchylenia standardowego

$$\left[ S \sqrt{\frac{n-1}{\chi_{1-\frac{\alpha}{2}, n-1}^2}}, S \sqrt{\frac{n-1}{\chi_{\frac{\alpha}{2}, n-1}^2}} \right].$$

# Rozkład $F$

Jeśli  $U \sim \chi^2(n_1)$  i  $V \sim \chi^2(n_2)$ , przy czym zmienne są niezależne, to

$$\frac{\frac{U}{n_1}}{\frac{V}{n_2}} \sim F(n_1, n_2),$$

gdzie  $F(n_1, n_2)$  jest **rozkładem  $F$**  o  $n_1$  i  $n_2$  stopniach swobody, zwanym też **rozkładem Snedecora**<sup>9</sup> albo **rozkładem Fishera-Snedecora**.

---


<sup>9</sup>George Waddel Snedecor (1881–1974) — amerykański matematyk i statystyk

# Definicja rozkładu $F$

Jest to rozkład ciągły o gęstości

$$f(x) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)\left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} x^{\frac{n_1}{2}-1}}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)\left(1+\frac{n_1}{n_2}x\right)^{\frac{n_1+n_2}{2}}} & \text{dla } x > 0, \\ 0 & \text{dla } x \leq 0. \end{cases}$$

# Gęstość rozkładu $F$



# Własności rozkładu $F$

- ❶ Jeśli  $X \sim F(n_1, n_2)$ , to  $\frac{1}{X} \sim F(n_2, n_1)$ .
- ❷ Jeśli  $X \sim t_n$ , to  $X^2 \sim F(1, n)$ .
- ❸ Jeśli  $f_{p,n_1,n_2}$  jest kwantylem rzędu  $p$  rozkładu  $F(n_1, n_2)$ , to

$$f_{p,n_1,n_2} = \frac{1}{f_{1-p,n_2,n_1}}.$$

# Porównanie wariancji rozkładów normalnych I

Zakładamy, że dane są dwie niezależne próby losowe o licznosciach  $n_1$  i  $n_2$  z rozkładów  $\mathcal{N}(m_1, \sigma_1)$  i  $\mathcal{N}(m_2, \sigma_2)$ . Ponieważ

$$\frac{(n_i - 1)S_i^2}{\sigma_i^2} \sim \chi^2(n_i - 1),$$

więc

$$F = \frac{\frac{S_1^2}{\sigma_1^2}}{\frac{S_2^2}{\sigma_2^2}} \sim F(n_1 - 1, n_2 - 1).$$

Stąd

$$P\left(f_{\frac{\alpha}{2}, n_1 - 1, n_2 - 1} \leq \frac{S_1^2 \sigma_2^2}{S_2^2 \sigma_1^2} \leq f_{1 - \frac{\alpha}{2}, n_1 - 1, n_2 - 1}\right) = 1 - \alpha.$$



# Porównanie wariancji rozkładów normalnych II

Zatem przedział ufności dla ilorazu  $\frac{\sigma_2^2}{\sigma_1^2}$  na poziomie ufności  $1 - \alpha$  ma postać

$$\left[ \frac{S_2^2}{S_1^2} f_{\frac{\alpha}{2}, n_1-1, n_2-1}, \frac{S_2^2}{S_1^2} f_{1-\frac{\alpha}{2}, n_1-1, n_2-1} \right] =$$

$$\left[ \frac{S_2^2}{S_1^2} \frac{1}{f_{1-\frac{\alpha}{2}, n_2-1, n_1-1}}, \frac{S_2^2}{S_1^2} f_{1-\frac{\alpha}{2}, n_1-1, n_2-1} \right]$$

## Uwagi o innych rozkładach

- Z Centralnego Twierdzenia Granicznego wynika, że dla dużych  $n$  statystyka  $Z$  ma w przybliżeniu rozkład  $\mathcal{N}(0, 1)$ , zatem można na jej podstawie konstruować (przybliżone) przedziały ufności dla średniej w przypadku znanej wariancji. W praktyce za wystarczające uważa się  $n \geq 30$ , dla rozkładów wyraźnie skośnych  $n \geq 40$ .
- Analogicznie w przypadku nieznanej wariancji do konstrukcji przedziału ufności dla średniej stosuje się statystykę  $T$  przyjmując, że dla niezbyt małych wartości  $n$  ( $n \approx 20$ ) ma ona rozkład zbliżony do rozkładu  $t$ .
- Przedstawiona metoda konstrukcji przedziałów ufności dla wariancji i ilorazu wariancji nie dopuszcza podobnego uogólnienia.

# Hipotezy statystyczne

Rozważamy model statystyczny  $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ .

## Definicja

**Hipotezą statystyczną** nazywamy dowolny niepusty podzbiór  $\mathcal{P}$ .

W praktyce wyróżniamy jedną hipotezę zwaną **hipotezą zerową** ( $H_0$ ), która podlega weryfikacji, natomiast  $H_1 = \mathcal{P} \setminus H_0$  nazywamy **hipotezą alternatywną**.

Hipotezę jednoelementową nazywamy **hipotezą prostą**, wieloelementową nazywamy **hipotezą złożoną**.

# Hipotezy dotyczące parametrów rozkładu

Jeśli hipotezy dotyczą nieznanego parametru  $\theta$ , to zbiór możliwych hipotez jest jednoznacznie wyznaczony przez zbiór możliwych wartości parametru. Można zatem utożsamić te dwa zbiory, tzn. przyjąć, że

$$H_0 \subset \Theta, \quad H_1 = \Theta \setminus H_0.$$

# Weryfikacja hipotezy zerowej

Weryfikacja hipotezy zerowej polega na:

- skonstruowaniu statystyki  $U$  o znanym rozkładzie dokładnym lub asymptotycznym;
- ustaleniu zbioru  $C$  tych wartości  $U$ , których wystąpienie uznaje się za wspierające **odrzućnię hipotezy zerowej na korzyść hipotezy alternatywnej**.

## Definicja

Statystykę  $U$  nazywamy **testem hipotezy zerowej  $H_0$  przeciwko hipotezie alternatywnej  $H_1$** , a zbiór  $C$  zbiorem krytycznym testu.

# Błędy testów statystycznych

## Definicja

**Błędem pierwszego rodzaju** nazywa się odrzucenie  $H_0$ , gdy jest ona prawdziwa. Prawdopodobieństwo wystąpienia błędu pierwszego rodzaju, tzn.

$$\alpha = P(U \in C | H_0)$$

nazywa się **poziomem istotności testu**.

**Błędem drugiego rodzaju** nazywa się odrzucenie  $H_1$ , gdy jest ona prawdziwa dla pewnej alternatywnej wartości  $\theta$ . Dla zadanej alternatywnej wartości  $\theta$  prawdopodobieństwo niepopęlnienia błędu drugiego rodzaju nazywa się **mocą testu**, tzn.

$$1 - \beta = P(U \in C | H_1(\theta)).$$

# Uwagi

- 1 Moc testu można zwiększać albo przez zwiększenie liczności próby, albo przez zwiększenie poziomu istotności.
- 2 Typowo stosowane poziomy istotności to: 0,05; 0,02; 0,01; 0,001.

# Test dla wartości średniej przy znanej wariancji I

Mamy  $\mathcal{P} = \{\mathcal{N}(\mu, \sigma) : \mu \in \mathbb{R}\}$  dla ustalonego  $\sigma > 0$ . Ustalamy hipotezy

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0.$$

Jako statystykę testową bierzemy

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}},$$

o której wiemy, że ma rozkład  $\mathcal{N}(0, 1)$  o ile prawdziwa jest  $H_0$ . Jeśli  $H_1$  jest prawdziwa dla pewnego  $\mu$ , to

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} + \frac{\mu - \mu_0}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}\left(\frac{\mu - \mu_0}{\frac{\sigma}{\sqrt{n}}}, 1\right).$$



## Test dla wartości średniej przy znanej wariancji II

Zatem dla zadanego poziomu istotności  $\alpha$  mamy

$$P(Z \leq -z_{1-\frac{\alpha}{2}} \text{ lub } Z \geq z_{1-\frac{\alpha}{2}} | H_0) = \alpha,$$

czyli możemy przyjąć

$$C = (-\infty, -z_{1-\frac{\alpha}{2}}] \cup [z_{1-\frac{\alpha}{2}}, +\infty).$$

Np. dla poziomu istotności 0,01 mamy

$$C = (-\infty, -2.5758293] \cup [2.5758293, +\infty).$$

# $p$ -wartości

## Definicja

**$p$ -wartością** dla zaobserwowanej wartości statystyki testowej nazywamy najmniejszy poziom istotności, przy którym ta wartość prowadzi do odrzucenia hipotezy zerowej.

# Przykład

Dla testu równości wartości średnich przy znanej wariancji z dwustronną hipotezą alternatywną ( $\mu \neq \mu_0$ ) mamy

$$p(z) = P(Z \leqslant -|z| \text{ lub } Z \geqslant |z| | H_0) = 2P(Z \geqslant |z| | H_0) = 2(1 - \Phi(|z|)).$$

Natomiast dla hipotezy jednostronnej  $\mu > \mu_0$  mamy

$$p(z) = P(Z \geqslant z | H_0) = 1 - \Phi(z).$$

# Uwagi

- ❶  $p$ -wartość pozwala uniezależnić się do pewnego stopnia od arbitralnego wyboru poziomu istotności.
- ❷ Małe  $p$ -wartości wspierają przekonanie o fałszywości  $H_0$  i prawdziwości  $H_1$ .
- ❸ Konwencjonalnie jako próg odrzucenia  $H_0$  przyjmuje się 0,05.
- ❹  $p$ -wartość **nie jest** prawdopodobieństwem prawdziwości  $H_0$ , ani fałszywości  $H_1$ .

## Test $t$

Test dla wartości średniej z **nieznanym** odchyleniem standardowym nazywa się **testem  $t$**  albo **testem Studenta**. Analogicznie do konstrukcji przedziałów ufności jako statystykę testową bierzemy

$$T = \frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}.$$

Jeśli rozkład wyjściowy jest rozkładem normalnym i spełniona jest

$$H_0 : \mu = \mu_0,$$

to  $T \sim t_{n-1}$ . W innym przypadku prawdziwy rozkład  $T$  przybliża się przez  $t_{n-1}$ .

## Test $t$ — c. d.

Wobec tego zbiór krytyczny na poziomie istotności  $\alpha$  dla dwustronnej hipotezy alternatywnej

$$H_1 : \mu \neq \mu_0$$

ma postać

$$C = \{t : t \leq -t_{1-\frac{\alpha}{2}, n-1} \text{ lub } t \geq t_{1-\frac{\alpha}{2}, n-1}\},$$

natomiast  $p$ -wartość w tym wypadku wynosi

$$p(t) = 2P(T \geq |t| \mid H_0) = 2(1 - F_{n-1}(|t|)),$$

gdzie  $F_{n-1}$  jest dystrybuantą  $t_{n-1}$ .

# Przykład

```
x <- rnorm(20, mean = 3, sd = 2)
t.test(x, mu = 2)
```

```
##
##  One Sample t-test
##
## data:  x
## t = 0.96355, df = 19, p-value = 0.3474
## alternative hypothesis: true mean is not equal to 2
## 95 percent confidence interval:
##  1.461853 3.456324
## sample estimates:
## mean of x
##  2.459089
```

## Test $t$ — $H_1$ jednostronna $\mu > \mu_0$

W tym przypadku wartościami  $T$  wspierającymi odrzucenie  $H_0$  na rzecz  $H_1$  są duże liczby dodatnie, zatem na poziomie istotności  $\alpha$  właściwy jest zbiór krytyczny

$$C = [t_{1-\alpha, n-1}, +\infty).$$

Natomiast  $p$ -wartość wynosi

$$p(t) = P(T \geq t | H_0) = 1 - F_{n-1}(t).$$



# Przykład

```
t.test(x, mu = 2, alternative = "greater")
```

```
##  
## One Sample t-test  
##  
## data:  x  
## t = 0.96355, df = 19, p-value = 0.1737  
## alternative hypothesis: true mean is greater than 2  
## 95 percent confidence interval:  
##  1.635231      Inf  
## sample estimates:  
## mean of x  
##  2.459089
```

## Test $t$ — $H_1$ jednostronna $\mu < \mu_0$

W tym przypadku wartościami  $T$  wspierającymi odrzucenie  $H_0$  na rzecz  $H_1$  są duże co do wartości bezwzględnej liczby ujemne, zatem na poziomie istotności  $\alpha$  właściwy jest zbiór krytyczny

$$C = (-\infty, t_{\alpha, n-1}] = (-\infty, -t_{1-\alpha, n-1}].$$

Natomiast  $p$ -wartość wynosi

$$p(t) = P(T \leq t | H_0) = F_{n-1}(t).$$

## Test $t$ dla dwu prób — równe wariancje

Analogicznie jak w przypadku konstrukcji przedziałów ufności używamy statystyki

$$T = \frac{(\bar{X} - \bar{Y}) - (m_1 - m_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

i dla dwustronnej hipotezy alternatywnej

$$m_1 \neq m_2$$

na poziomie istotności  $\alpha$  otrzymujemy zbiór krytyczny

$$C = (-\infty, -t_{1-\frac{\alpha}{2}, n_1+n_2-2}] \cup [t_{1-\frac{\alpha}{2}, n_1+n_2-2}, +\infty),$$

natomiast  $p$ -wartość wynosi

$$p(t) = 2P(T \geq |t| \mid H_0) = 2(1 - F_{n_1+n_2-2}(|t|)).$$

# Przykład

```
y <- rnorm(30, mean = 2, sd = 2)
t.test(x, y, var.equal = TRUE)
```

```
##
## Two Sample t-test
##
## data: x and y
## t = 0.58564, df = 48, p-value = 0.5609
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -0.8506326 1.5498192
## sample estimates:
## mean of x mean of y
## 2.459089 2.109495
```

## Test $t$ dla dwu sparowanych prób

Zakładamy równe licznosci  $X_i$  i  $Y_i$  oraz wspólny rozkład normalny różnic  $D_i = X_i - Y_i$ . Wtedy statystyką testową jest

$$T = \frac{X_i - Y_i - (m_1 - m_2)}{\frac{S_D}{\sqrt{n}}} \sim t_{n-1}$$

i dalszy ciąg jest jak w przypadku testu dla pojedynczej próby.

## Przykład

```
z <- rnorm(20, mean = 1, sd = 5)
t.test(x, z, paired = TRUE)
```

```
##
## Paired t-test
##
## data: x and z
## t = 2.4341, df = 19, p-value = 0.02497
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
##  0.3339504 4.4327913
## sample estimates:
## mean difference
##      2.383371
```

## Test $F$ równości wariancji I

Tutaj  $X_1, \dots, X_{n_1} \sim \mathcal{N}(m_1, \sigma_1)$  i  $Y_1, \dots, Y_{n_2} \sim \mathcal{N}(m_2, \sigma_2)$ . Przyjmujemy

$$H_0 : \sigma_1^2 = \sigma_2^2.$$

Wtedy

$$F = \frac{\frac{S_1^2}{\sigma_1^2}}{\frac{S_2^2}{\sigma_2^2}} = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

i dla dwustronnej hipotezy alternatywnej

$$H_1 : \sigma_1^2 \neq \sigma_2^2$$

otrzymujemy na poziomie istotności  $\alpha$  zbiór krytyczny

$$C = \left(0, f_{\frac{\alpha}{2}, n_1-1, n_2-1}\right] \cup \left[f_{1-\frac{\alpha}{2}, n_1-1, n_2-1}, +\infty\right),$$

## Test $F$ równości wariancji II

a  $p$ -wartość wynosi

$$p(f) = \begin{cases} 2F_{n_1-1, n_2-1}(f) & \text{dla } f < f_{1/2, n_1-1, n_2-1}, \\ 2(1 - F_{n_1-1, n_2-1}(f)) & \text{dla } f \geq f_{1/2, n_1-1, n_2-1}, \end{cases}$$

gdzie  $F_{n_1-1, n_2-1}$  jest dystrybuantą rozkładu  $F(n_1 - 1, n_2 - 1)$ .

Podobnie dla jednostronnej hipotezy alternatywnej

$$H_1 : \sigma_1^2 > \sigma_2^2$$

zbiór krytyczny na poziomie istotności  $\alpha$  ma postać

$$C = [f_{1-\alpha, n_1-1, n_2-1}, +\infty),$$

a  $p$ -wartość wynosi

$$p(f) = 1 - F_{n_1-1, n_2-1}(f).$$



# Przykład

```
var.test(x, y)
```

```
##  
## F test to compare two variances  
##  
## data: x and y  
## F = 1.1066, num df = 19, denom df = 29,  
## p-value = 0.7871  
## alternative hypothesis: true ratio of variances is not equal  
## 95 percent confidence interval:  
## 0.4959402 2.6579380  
## sample estimates:  
## ratio of variances  
## 1.106578
```

# Przykład

```
var.test(z, x, alternative = "greater")
```

```
##  
## F test to compare two variances  
##  
## data: z and x  
## F = 3.1032, num df = 19, denom df = 19,  
## p-value = 0.008754  
## alternative hypothesis: true ratio of variances is greater  
## 95 percent confidence interval:  
## 1.431192 Inf  
## sample estimates:  
## ratio of variances  
## 3.103184
```